Étiquetage de la race de chien depuis une image à l'aide d'un réseau de neurone convolutif

Antoine Gaulin , **Othman Mounir** , **Arthur Pulvéric** et **Anis Redjdal**
Polytechnique Montréal

Abstract

L'article a pour but de présenter un modèle de classification et d'étiquetage d'images de chiens en fonction de leur race. Nous avons proposé une architecture basée sur GoogLeNet afin de bénificer de ses avantages et d'en apprendre plus sur le sujet. Nous sommes parvenus à construire un modèle plus performant qu'un article utilisant un modèle similaire. Cependant, les performances d'un réseau spécialisé en détection de races de chiens ne sont toujours pas acceptables pour identifier les images. Nous recommandons d'utiliser un modèle plus généraliste pour profiter de ses performances.

1 Introduction

1.1 Motivations

Les réseaux de neurones convolutifs (CNN) permettent de faire de la classification d'image de façon rapide et performante. Ainsi, avec des images de chiens, il est possible de calculer la probabilité qu'un canidé présent dans une image appartienne à une race plutôt qu'une autre. Pour aider la SPCA à se créer un inventaire en ligne de tous ses chiens, et encourager le commerce en ligne, nous voulons concevoir un réseau de neurones qui permet de faire de la classification automatique à partir des images de chien. De cette façon, les clients souhaitant faire l'acquisition d'une race spécifique auront plus de facilité à la retrouver sur leur site internet.

Dans la pratique, un réseau de neurones convolutif classique présente des difficultés pour la classification d'objets présentant de nombreuses caractéristiques communes, ce qui est le cas pour les chiens de la base de données. La figure 1 illustre bien ce problème : les chiens présentés ont beaucoup de caractéristiques communes, mais n'appartiennent pas à la même race. L'objectif ici est donc d'implémenter un modèle capable d'obtenir des performances acceptables pour la prédiction de races de chien.

1.2 Travaux antérieurs

L'article *Using Convolutional Neural Networks to Classify Dog Breeds* [Hsu, 2015] est un incontournable. Concrètement, les auteurs proposent deux architectures différentes capables de différencier les petites variations entre les races. Le premier modèle est basé sur l'architecture de LeNet, dont chaque couche de convolution est un filtre avec 2 paramètres : le nombre de pixels qu'elles prennent en entrée et le nombre de canaux en sortie. Le second modèle reprend l'architecture de GoogLeNet, dont chaque couche de convolution est une combinaison de filtres eux-mêmes composés de réseaux de neurones.

Figure 1: De gauche à droite, un Malmute, un Eskimo et un Husky

Un autre papier intéressant est *Dog Breed Identification*. [LaRow *et al.*, 2016] Il y est présenté un projet ayant pour but de prédire les races des chiens à partir d'images. Ce projet utilise des techniques d'apprentissage automatique et de vision par ordinateur. Un réseau de neurones convolutionnel permet, dans un premier temps, d'identifier les points clés des visages des chiens. Ensuite, des descripteurs SIFT (*Scale-Invariant Feature Transform*) et des histogrammes de couleur utilisent ces points clés pour extraire des *features*. Enfin, un classificateur de type machine à vecteur de support (SVM) prédit la race du chien avec une précision de 52%. Il est à noter que dans 90% des cas, la race du chien à trouver est présente dans les 10 prédictions les plus probables parmis 133 races au total dans la base de données. Ces performances sont supérieures à ce que peuvent faire la plupart des humains.

Dans ce travail, nous nous inspirons d'un modèle proposé par le premier article. En effet, la simplicité d'architecture et ses performances sont totalement adaptées aux contraintes que nous rencontrons. Nous allons ajouter un algorithme qui applique une étiquette sur l'image.

2 Approche théorique

2.1 GoogLeNet

Le modèle GoogLeNet créé par Google possède le mot LeNet dans son nom, car il rend hommage à son prédécesseur LeNet qui est un des premiers modèles de convolution à apporter de réelles prédictions de contenu d'images. Avant le

développement de GoogLeNet, beaucoup d'autres modèles de convolution ont vu le jour comme AlexNet, mais le modèle de Google reste celui qui a le pourcentage d'erreur le plus bas et qui est donc le plus performant tel que présenté sur la figure 2 [Tsang, 2018].

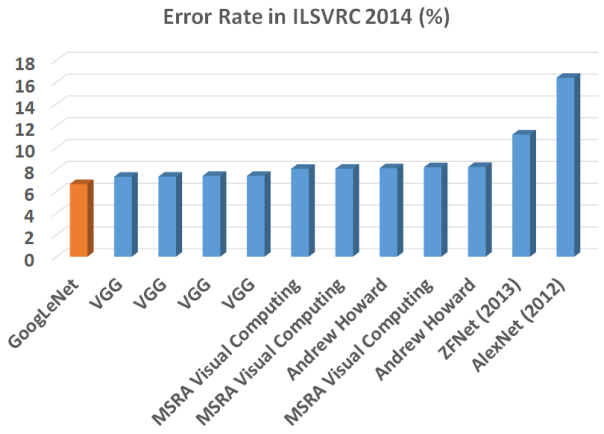

Figure 2: Les modèles participants à l'ILSVRC 2014

L'architecture de ce réseau GoogleNet est très différente des précédents réseaux existants. Il contient des convolutions 1×1 au milieu du réseau et le regroupement moyen global est utilisé à la fin du réseau au lieu d'utiliser des couches entièrement connectées. Ces deux techniques sont extraites d'un autre article intitulé *Network In Network*. [Lin *et al.*, 2013] Une autre technique, appelée module de création, consiste à avoir différentes tailles ou types de convolutions pour la même entrée. Ensuite, on empile toutes les sorties. Nous verrons plus en détail chacune de ces techniques.

2.2 Convolution 1×1

Dans GoogLeNet, la convolution 1×1 est utilisée comme module de réduction de dimension pour réduire le calcul. En réduisant le goulot d'étranglement du calcul, la profondeur et la largeur peuvent être augmentées. Prenons un exemple simple pour illustrer cela. Supposons que nous devons effectuer une convolution 5×5 sans utiliser la convolution 1×1 tel qu'illustré à la figure 3 [Tsang, 2018].

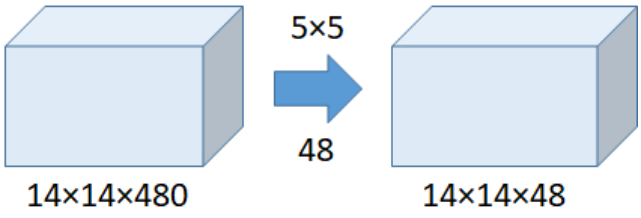

Figure 3: Convolution de 112,9 millions opérations

Voyons maintenant le nombre d'opérations effectuées si l'on ajoute une convolution 1×1 comme sur la figure 4 [Tsang, 2018].

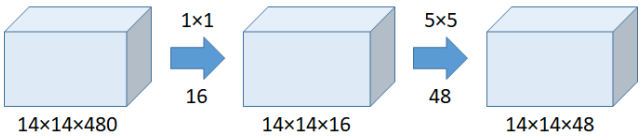

Figure 4: Convolution de 5,3 millions opérations

Les deux sous-modèles de convolution ci-dessus donnent le même résultat et sont donc équivalents. Cependant, lorsqu'on utilise la convolution 1×1 en plus on effectue beaucoup moins d'opérations, ce qui est moins couteux. Ainsi, la convolution 1×1 aide à réduire la taille du modèle, ce qui peut également aider à réduire les problèmes de généralisation.

2.3 Inception

Auparavant, comme avec AlexNet et VGGNet, la taille du filtre de convolution était fixée pour chaque couche. Mais avec le module Inception, les filtres de convolution 1×1, 3×3 et 5×5 ainsi que la couche *maxpooling* sont toutes appliquées à la sortie de la couche de neurones précédente et chaque résultat de chacune de ces couches est envoyé vers une couche de concaténation qui regroupe toutes ces sorties en un seul résultat. L'architecture de ce module est de la forme représentée à la figure 5. [Szegedy *et al.*, 2015]

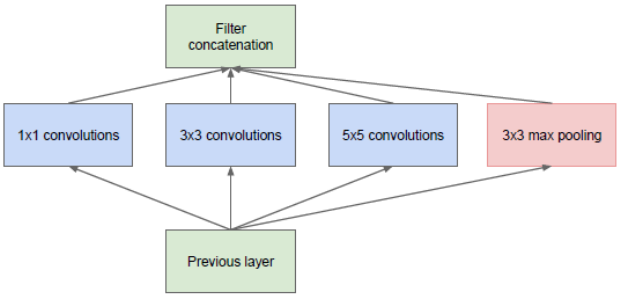

(a) Inception module, naïve version

Figure 5: Inception Naïf

Finalement, si on décide de regrouper et d'utiliser la convolution 1×1 dans notre module Inception, on réduit la dimension des couches 3×3 et 5×5 pour qu'elles soient moins couteuses. On garde donc la variété de résultats qu'offre l'assemblage de couches de convolution de différentes tailles enréduisant les dimensions des objets manipulés. Cela permet d'éviter une surcharge des opérations et les problèmes de généralisation illustrés par la figure 6. [Szegedy *et al.*, 2015]

2.4 Regroupement moyen global

Dans la plupart des CNN classiques déjà réalisés, on utilise une couche pleinement connectée (FC) à la fin du réseau. Elle peut être placée à la sortie de la dernière couche de convolution ou de *pooling* et relie toutes les entrées à toutes les sorties. Il y a autant de sorties que de classes possibles pour la catégorisation d'un objet. Dans notre cas, nous avons 120 classes qui représentent les 120 races de chiens différentes. Néanmoins, GoogLeNet n'utilise pas de couche

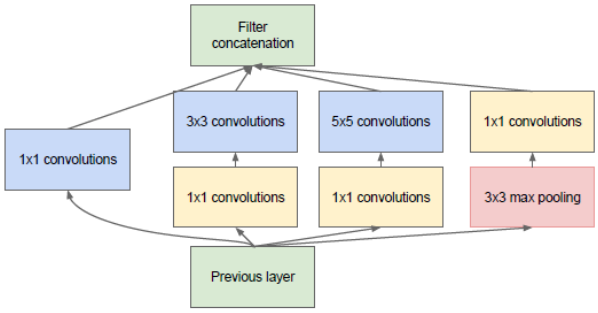

(b) Inception module with dimensionality reduction

Figure 6: Inception réduit

FC à la fin pour la classification, mais une couche de regroupement moyen global (GAP) qui calcule pour chaque entrée une moyenne de probabilité qu'il va envoyer directement à la sortie. On passe d'un tenseur de dimension $h \times w \times d$ à un tenseur de dimension $1 \times 1 \times d$ en faisant une moyenne des valeurs des dimensions h et w. Contrairement à FC, il n'y aura donc aucune matrice de poids à apprendre. Le concept du GAP est représenté à la figure 7. [Tsang, 2018]

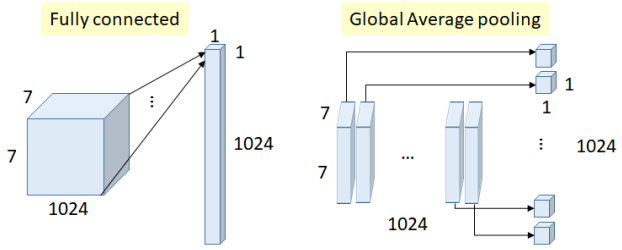

Figure 7: Comparaison de FC et GAP

On voit que le réseau FC utilise toutes les entrées pour déterminer chaque sortie, ce qui n'est pas le cas pour GAP. Le réseau GAP est donc moins couteux. De plus, une étude des auteurs a confirmé qu'un passage de la couche FC à la couche GAP améliore la précision du GoogLeNet de 0,6% ce qui n'est pas négligeable. [Tsang, 2018]

2.5 Méthodologie

Dans ce contexte de pandémie, nous devons limiter le projet à quelque chose de simple, qui permet toutefois de comprendre le fonctionnement d'un CNN moderne en profondeur. Ainsi, nous allons nous limiter à une seule architecture.

Premièrement, nous avons évalué s'il était possible d'ajouter des étiquettes à une image dans ses métadonnées à l'aide du langage Python. Nous avons trouvé la librairie IPTCInfo qui permet de faire cette tâche aisément.

Ensuite, nous avons cherché un jeu de données pour entrainer notre modèle. Les images retenues proviennent du *Stanford Dogs Dataset*. [Khosla *et al.*, 2011] Le fait que les clichés soient présents dans des répertoires nommés par la race permet facilement de retrouver l'étiquette pour faire l'entrainement supervisé. Aussi, le fait que le jeu de données soit différent de l'article permet d'explorer davantage les impacts du jeu de données par rapport au modèle.

Pour concevoir le modèle, nous utilisons un réseau GoogLeNet comme dans l'article *Using Convolutional Neural Networks to Classify Dog Breeds* [LaRow *et al.*, 2016]. Ainsi, il nous a été utile de consulter l'article de Google, *Going deeper with convolutions* [Szegedy *et al.*, 2015], afin de bien comprendre le fonctionnement du réseau.

Le modèle que nous avons implémenté en python à l'aide de couches de Pytorch est fortement inspiré du modèle GoogLeNet auquel nous avons décidé d'ajouter des couches de normalisation par sous-ensemble afin d'améliorer l'entrainement. En effet, nous avons implémenté une classe Inception composée de quatre branches de séparation du transformer, qui ont leur sortie regroupée à la fin de la classe. Ensuite, nous avons une classe GoogLeNet composée de trois couches de convolution suivies chacune d'une couche de normalisation par sous-ensemble puis d'une couche ReLU et enfin d'une couche de *pooling*. L'architecture implémentée est représentée par la figure 8. L'architecture est disponible dans le fichier googlenet.py sur le dépôt GitHub disponible à cette adresse : https://github.com/Anteige/INF8225

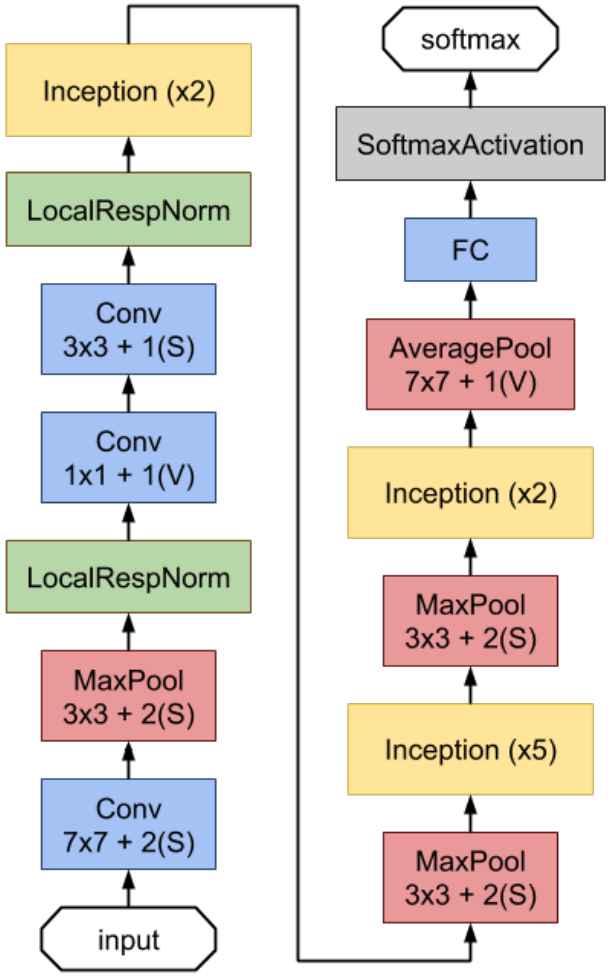

Figure 8: Architecture implémentée

3 Discussion

3.1 Entraînement

Afin de réaliser l'entrainement sur notre implémentation de GoogLeNet, nous avons choisi comme input 12000 images d'entrainement, soit 100 images par race de chien, de taille $3 \times 244 \times 244$. Chaque dimension représente respectivement, la couleur RBG, la longueur et la largeur. Ce jeu de données est importé de Kaggle. Nous l'avons choisi, car il est plutôt récent et les résultats des entrainements sur ce jeu de données à ce jour sont loin d'être performants. Pour ce qui est du modèle, nous avons choisi, à l'aide d'un ensemble de validation, des taux d'apprentissages égaux à 0,07 et 0,0005 et un momentum de 0,0005. L'algorithme d'optimisation employé est ADAM et la fonction de perte utilisée pour mesurer l'erreur après chaque mise à jour du modèle est l'entropie croisée.

Nous avons effectué plusieurs essais en variant le taux d'apprentissage, le nombre d'itérations et l'utilisation, ou non, d'une optimisation ADAM. Pour chaque essai, nous avons noté le score en top1 et en top10. Pour des fins de comparaisons, seule la moyenne a été retenue.

3.2 Résultats

Nombre d'itérations	top1 (%)	top10 (%)
1000	0.89	2.60
	0.87	2.66
	0.72	2.45
	0.84	2.67
	0.82	2.53
	$\mu = 0.83$	$\mu = 2.58$
300	0.65	2.38
	0.73	2.44
	0.75	2.42
	0.80	2.37
	0.59	2.30
	$\mu = 0.71$	$\mu = 2.38$
200	0.78	2.24
	0.84	2.38
	0.84	2.47
	0.71	2.40
	0.80	2.59
	$\mu = 0.79$	$\mu = 2.41$
100	0.77	8.11
	0.73	8.25
	0.63	8.23
	0.78	8.37
	0.80	8.59
	$\mu = 0.74$	$\mu = 8.31$

Table 1: Performances avec un taux d'apprentissage de 0,0005

3.3 Interprétation des résultats

Dans le tableau 1, on voit que les résultats de l'entrainement avec beaucoup d'itérations sont moins bons à partir de 100 itérations. En effet, on constate que même si l'erreur de la fonction de cout continue à diminuer après 100 itérations et qu'elle devient acceptable à partir de 500 itérations, les résultats ne vont pas dans ce sens, ce qui nous laisse penser que le modèle passe en surapprentissage au bout de 100 itérations d'entrainement.

Nombre d'itérations	top1 (%)	top10 (%)
1000	0.89	2.60
	0.87	2.66
	0.72	2.45
	0.84	2.67
	0.82	2.53
	$\mu = 0.83$	$\mu = 2.58$

Table 2: Performances avec un taux d'apprentissage et un L2 de 0,0005

Nombre d'itérations	top1 (%)	top10 (%)
50	0.96	8.86
	0.73	8.68
	0.70	8.40
	0.63	8.54
	0.84	8.96
	$\mu = 0.77$	$\mu = 8.69$

Table 3: Performances avec un taux d'apprentissage de 0,07

Dans le tableau 2, afin de mieux combattre le surapprentissage dû au grand nombre d'itérations d'entrainement, nous avons pensé à ajouter un terme L2 de régularisation à la fonction de perte. C'est une technique très utilisée en apprentissage profond. Nous remarquons cependant que la différence pour le score de précision n'est pas significative. En effet, il est normal que le terme de régularisation ne change pas ce score de précision car cette technique n'est pa s utilisée pour pour améliorer la reconnaissance et la classification mais plutôt pour diminuer un apprentissage trop pointilleux (qui va mener une difficulté de généralisation pour l'ensemble de test). Il est donc clair que si la reconnaissance et la classification n'ont pas un bon score de base, la régularisation avec l'ajout du terme L2 n'améliorera pas le score de précision.

Dans le tableau 3, ... TODO

3.4 Observations

Nous avons remarqué que la perte de la fonction de coût diminue très lentement lors de la phase d'entrainement. En effet, le modèle classique GoogLeNet réalisé par Google s'est entrainé sur une multitude d'objets et d'êtres vivants différents. Il a donc pu apprendre chaque *freatures* différente selon chaque entrée. Dans notre cas, nous avons décidé de ne pas utiliser la version préimplémentée du modèle de Google, en l'important depuis la libraire Pytroch. Nous l'avons implémentée nous-mêmes et avons refait son entrainement à partir de zéro. Notre modèle doit donc apprendre à reconnaitre différentes races de chiens uniquement.

Or, même si les chiens que nous lui avons donnés en entrée sont de races différentes, ils ont quand même énormément de similitudes, comme un museau, de longues oreilles, une

posture à quatre pattes, etc. Le modèle de convolution extrait donc souvent des caractéristiques similaires à chaque fois, même si les chiens sont de race différente, ce qui fait toute la complexité de notre apprentissage. Nous avons donc décidé d'ajouter la dimension de couleur RBG dans nos images d'entrée, en faisant l'hypothèse que l'apprentissage des couleurs pourrait aider à reconnaitre différentes races de chiens, qui sont souvent de couleurs différentes.

L'article que nous avons étudié pour faire ce projet a obtenu une précision de 10% sur la reconnaissance de races de chiens en utilisant le modèle de Google avec un jeu de données issu d'ImageNet. Il nous a donc semblé intéressant de tester notre propre implémentation du modèle de Google sur un jeu de données différent, afin de voir s'il arrive à obtenir de bons résultats en entrainant notre modèle uniquement sur des chiens.

Pour pallier au fait que la perte diminue très lentement, nous avons décidé de laisser le modèle s'entrainer pendant un nombre d'itérations d'entrainement de plus en plus grand. Nous sommes allés jusqu'à tester plus de 1000 itérations, ce qui a pris 18 heures environ.

4 Analyse

Nous avons donc une meilleure précision que l'article que nous avons étudié, en utilisant le même modèle GoogleNet avec 3 couches d'Inception. Selon nous, cela est dû à l'ajout de couches de normalisation par sous-ensemble ainsi qu'à l'entrainement exclusif sur des chiens. Notre jeu de données peut également avoir contribué à l'amélioration des performances du modèle.

La précision est néanmoins loin d'être bonne et utilisable comme nous le souhaitions. En effet, le but de notre projet était de modifier les mots-clés de chaque image selon la prédiction de notre modèle. Même si nous sommes arrivés à une perte sur une erreur d'entrainement suffisamment petite, le modèle a encore du mal à généraliser sur l'ensemble de tests à cause des similitudes qui existent entre les races de chiens. Dans l'article que nous avons décidé d'implémenter, nous trouvons des résultats de modèles GoogleNet composés respectivement de 3, 4, 6 et 7 couches inceptions. Le modèle que nous avons décidé d'implémenter est celui du réseau GoogLeNet à 3 couches inceptions. Par rapport à cela nous pouvons affirmer que notre modèle GoogleNet donne des résultats significativement meilleurs que l'article. Cependant, cette performance est insuffisante pour une classification proche de l'être humain.

Pour revenir à la remarque du tableau 1, posons-nous la question suivante : qu'est-ce que le modèle veut apprendre ? Et bien notre modèle est principalement basé sur des convolutions, il cherche donc à apprendre des filtres de convolution afin de reconnaitre les caractéristiques d'une image et pouvoir la classifier selon ces caractéristiques. De plus, à l'aide des couches de *pooling*, il cherche à réduire l'information inutile qui n'est pas en rapport avec les caractéristiques qu'il souhaite apprendre. Or, sachant que les chiens ont tous des caractéristiques similaires, notre modèle va apprendre ces caractéristiques minimisées, par les couches de *pooling*, et ne saura donc plus les utiliser pour classifier les races de chiens. En somme, augmenter le nombre d'itérations de l'apprentissage ne nous aidera pas à mieux apprendre ces caractéristiques, qui diffèrent selon chaque race de chien, mais bien au contraire, notre GoogLeNet va vite tomber dans le surapprentissage, car il va apprendre sans cesse des caractéristiques qui ne lui apporteront pas suffisamment de détails pour classifier les races de chiens de notre jeu de données.

En conclusion de cette analyse, nous pensons qu'il serait préférable de réduire au minimum les tailles des filtres de convolution avec les couches de *pooling* car ceux-ci font perdre de l'information précieuse. Le problème avec cette méthode est que l'information à traiter sera en conséquence plus grande et nous aurons besoin d'un réseau beaucoup plus profond que ceux utilisables à notre niveau d'un point de vue matériel et temporel. Un jeu de données plus grand pourrait également aider pour un apprentissage de détail plus profond et pour réduire le risque de surapprentissage.

References

[Hsu, 2015] David Hsu. Using convolutional neural networks to classify dog breeds. Technical report, Standford, 2015.

[Khosla *et al.*, 2011] Aditya Khosla, Nityananda Jayadevaprakash, Bangpeng Yao, and Li Fei-Fei. Novel dataset for fine-grained image categorization. In *First Workshop on Fine-Grained Visual Categorization, IEEE Conference on Computer Vision and Pattern Recognition*, Colorado Springs, CO, June 2011.

[LaRow *et al.*, 2016] Whitney LaRow, Brian Mittl, and Vijay Singh. Dog breed identification. Technical report, Standford, 2016.

[Lin *et al.*, 2013] Min Lin, Qiang Chen, and Shuicheng Yan. Network in network, 2013. cite arxiv:1312.4400Comment: 10 pages, 4 figures, for iclr2014.

[Szegedy *et al.*, 2015] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Computer Vision and Pattern Recognition (CVPR)*, 2015.

[Tsang, 2018] Sik Ho Tsang. Review: Googlenet (inception v1)— winner of ilsvrc 2014 (image classification), Aug 2018.